

# dpsmodel

## dpsmodel

### Motivation

只希望直接的衡量循环的强弱，不希望面板状态影响循环强弱分析，因此做一些结构上的分离。

灵感还是来源于统计那篇，大致想法就是，后台如何统计数据，如何从面板还原真实的数据。面板不同得到的不同数据能否用做分析。

大致上就是收集玩家的技能序列，得到决策向量方向，将其与最优决策向量做夹角分析啥的。

以及对前文做点补充，如何统计熟练度分布啥的。

### 1

得益于之前的分析，我们产生了一些可以复用的工具，并且基于这些，又能进行下一步的分析。

在之前文章中，我们给出了这样的一个式子：

$$D = \begin{vmatrix} \beta_{\text{addition}} & 0 & 0 & 0 \\ 0 & \gamma_{\text{level}} & 0 & 0 \\ 0 & 0 & \delta_{\text{pve}} & 0 \\ 0 & 0 & 0 & \omega_{\text{cof}} \end{vmatrix} \cdot \mathbf{s}^\top \mathbf{p}$$

其中：

$$\mathbf{s} = \begin{bmatrix} \alpha_{\text{base}} \cdot d_{\text{base}} \\ d_{\text{rand}} \\ \alpha_{\text{global}} \cdot \alpha_{\text{ap}} \\ \alpha_{\text{global}} \cdot \alpha_{\text{weapon}} \\ \alpha_{\text{global}} \cdot \alpha_{\text{surplus}} \end{bmatrix} \quad \mathbf{p} = \beta_{\text{overcome}} \kappa_{\text{strain}} \begin{bmatrix} 1 \\ 1 \\ AP \\ \text{Weapon} \\ \text{surplus} \end{bmatrix}$$

我们将其进行改写，把  $\beta_{\text{addition}}$  提出式子，放进向量  $\mathbf{s}$  内，得到如下式子：

$$D = S_c \cdot \mathbf{s}^\top \mathbf{p}$$

其中：

$$S_c = \begin{vmatrix} \beta_{\text{ignore}} & 0 & 0 & 0 \\ 0 & \gamma_{\text{level}} & 0 & 0 \\ 0 & 0 & \delta_{\text{pve}} & 0 \\ 0 & 0 & 0 & \omega_{\text{cof}} \end{vmatrix}, \quad \mathbf{s} = \begin{bmatrix} \beta_{\text{addition}} \alpha_{\text{base}} \cdot d_{\text{base}} \\ \beta_{\text{addition}} d_{\text{rand}} \\ \beta_{\text{addition}} \alpha_{\text{global}} \cdot \alpha_{\text{ap}} \\ \beta_{\text{addition}} \alpha_{\text{global}} \cdot \alpha_{\text{weapon}} \\ \beta_{\text{addition}} \alpha_{\text{global}} \cdot \alpha_{\text{surplus}} \end{bmatrix}$$

那么  $\mathbf{s}_t$  为  $t$  时刻技能的系数。

那么全局的DPS可以写为：

$$D_{\text{total}} = S_c \sum_{t=0}^T \mathbf{s}_t^\top \mathbf{p}$$

那么，给定一段时间区间，该区间内这一组技能的总系数，或者叫该技能循环的总系数，我们定义如下：

$$\mathbf{v} = \sum_{t=0}^T \mathbf{s}_t$$

自然，存在几个量需要衡量。其一为，循环对不对；其二为，打没打出装备的水平。

### 1. 循环的熟练度

怎么给自己的循环的打分，最常见的做法就是求总DPS的比例，我能打到百分之多少多少的计算器理想值，这也是很符合一贯以来的直觉的。

上式的  $S_c$  的定义其实就是门派强度的定义，结合了无视防御，pve非侠系数的一个常量。依旧是很符合客观直觉，这也是策划习以为常调节门派强度的一个手段，即直接调整非侠系数。

首先该问题肯定是存在最优解的，也是很容易求出的，毕竟有限的状态空间，有限的决策空间。

当面板状态已经确定的时候，不妨直接定义其最优解为：

$$\mathbf{v}^* = \arg \max_{v \in \mathcal{V}} \mathbf{v}^\top \mathbf{p}$$

我们平常进行DPS的比较，占比评分多是基于这样的一种指标：

$$\text{熟练度} := \frac{\mathbf{v}^\top \mathbf{p}}{\mathbf{v}^{*\top} \mathbf{p}}$$

当然，这样的指标分析依旧是不可避免的会涉及到面板状态的计算。

也会有一个问题，那就是我小修了一下循环，也能打出相同比值的操作，那算个什么事。那能说明我复刻了最优策略吗？不太能吧。

因此，我们不妨直接考虑另一个指标，循环的对齐程度，这也是在之前的文章中进行分析时用的一种处理方法：

$$Similarity = \frac{\langle \mathbf{v}, \mathbf{v}^* \rangle}{\|\mathbf{v}\| \cdot \|\mathbf{v}^*\|}$$

这样的指标有一个好处，天然的避免对延迟的分析，你是5分打完的技能还是5分30打完的技能都没有任何影响，只是简单的衡量了循环是否与最优的循环是对齐的。

## 2. 循环与面板的适配程度

为什么提这样的一个指标，原因也很简单。

不同的面板是会产生不同的循环的，高破招的面板会打高破的循环，高攻击的面板，会打高攻的循环，这是很自然的一个事情。

还是一个问题抛出，为什么我们配装需要根据循环去配装？

从我们分析得出的式子去看，这是因为我们配装本质是通过分配属性值在向量  $\mathbf{p}$  上。

那么，如果需要最大化  $\mathbf{v}^\top \mathbf{p}$  的乘积，那么什么事情会发生。

在不同面板下，玩家会选择不同循环，因此，我们只关心给定循环  $\mathbf{v}^*$ ，适合该循环的最优面板记为：

$$\mathbf{p}^* = \arg \max_{\mathbf{p} \in \mathcal{P}} \mathbf{v}^{*\top} \mathbf{p}$$

如果我们显式的考虑他们，那么该夹角就是配装与循环的适配程度。

$$Adaptability = \frac{\langle \mathbf{v}^*, \mathbf{p} \rangle}{\|\mathbf{v}^*\| \cdot \|\mathbf{p}\|}$$

该定义只关心面板方向是否对齐，不受属性总量或装备上限影响，因此适用于评估玩家是否“打出了自己配装的强度方向”。

在上式的推导过程中，我们又得出了另一个值得分析的量。

那就是循环向量  $\mathbf{v}$

我们收集每一位玩家在该boss下的循环向量  $\{\mathbf{v}_i\}_{i=1}^N$

我们的目的是为了推出群体的分布，大概就是，大家都在打什么打法，做什么样的事情，我们希望刻画群体的这个特征。

我们不妨先记群体N的经验分布：

$$\bar{\mu}_V^n = \frac{1}{n} \sum_{i=1}^n \delta_{v_i}$$

注意到这里经验分布，他不是个数，是一个概率分布。

由概率分布的大数定律我们可以得到全服的打法风格。

那么当 n 取足够大时，在弱收敛意义下，经验分布收敛到全服分布。

$$\bar{\mu}_V^n \xrightarrow{w} \mu$$

在这么分析之下，我们又又又得到了一项工具。

按整个思考链路来说，每一环都环环相扣，虽然参杂了很多假设在里边，但是这些假设从另一个层面上被证实。

比如我们提出的夹杂门派熟练度的基础DPS模型，他就能很好的从DPS计算公式出发，推导出形式一致的式子。

这使得我们的结论都能够得到保障，并非是空中楼阁，浮于理论

既然我们能得到某个门派的群体分布。

那是不是就能够刻画门派与门派之间的差异性呢？

一个门派难与不难，能够很直观的体现在分布上。

越简单的门派，理论上，他的分布会越集中，因为其复刻完整循环难度很低。

越复杂的分派，理论上，他的分布会越分散，因为其复刻完整循环的难度很高。这会导致，因为细节上的失误偏离了最优方向。

他们之间的差异，仅仅只是分布的形状上的差异。

我们不妨考虑使用 Wasserstein 距离去评估两个分布的差异，或者说是距离。

$$W_1(\mu_A, \mu_B) = \inf_{\pi \in \Pi(\mu_A, \mu_B)} \int_{\mathbb{R}^d \times \mathbb{R}^d} \|x - y\| d\pi(x, y)$$

Wasserstein 距离能够很好的刻画分布之间的形状上的差异。用 W1 简记一下。

事实上，W1 距离越小，这两个分布会越接近。

**Theorem 5.5** *For any  $p \geq 1$ , if  $(\mu_n)_{n \geq 1}$  and  $\mu$  are in  $\mathcal{P}_p(E)$ ,  $\lim_{n \rightarrow \infty} W_p(\mu_n, \mu) = 0$  if and only if  $(\mu_n)_{n \geq 1}$  converges toward  $\mu$  for the weak convergence of probability measures and:*

$$\lim_{n \rightarrow \infty} \int_E d(x_0, x)^p d\mu_n(x) = \int_E d(x_0, x)^p d\mu(x), \quad (5.15)$$

*for one (and hence for all)  $x_0 \in E$ . The latter is also equivalent to the fact that  $(\mu_n)_{n \geq 1}$  converges toward  $\mu$  for the weak convergence of probability measures and is  $p$ -uniformly integrable, namely*

$$\lim_{r \rightarrow \infty} \sup_{n \geq 1} \int_E d(x_0, x)^p \mathbf{1}_{\{d(x_0, x) \geq r\}} d\mu_n(x) = 0. \quad (5.16)$$